

# Prédiction de l'Admission Universitaire

Mathématiques Pour La Sciences Des Données

Présenté par :

- Manal Rhoni Aref
- Souhaila Benaouate



# Introduction & Objectif

## Contexte

- L'admission en Master est un processus hautement compétitif.
- Les étudiants et les universités ont besoin d'outils pour évaluer objectivement les dossiers.

## Objectif du Projet

- Développer un modèle prédictif capable de classer automatiquement un candidat comme "**Admis**" ou "**Rejeté**".
- Identifier les critères académiques les plus déterminants (CGPA, GRE, etc.).

## Notre Approche

1. **Exploration** : Analyse et nettoyage des données.
2. **Prétraitement** : Normalisation et équilibrage des classes.
3. **Modélisation** : Comparaison entre **Régression Logistique** et **Arbre de Décision**.



# Présentation du Dataset

## Source des Données

- Fichier : [Admission\\_Prediction.csv](#)
- Taille : 500 candidats (Lignes) x 8 variables (Colonnes).

## Les Variables (Features)

- **Scores Académiques** : GRE Score (sur 340), TOEFL Score (sur 120), CGPA (sur 10).
- **Dossier Qualitatif** : University Rating (1-5), SOP (Statement of Purpose), LOR (Lettre de Recommandation).
- **Recherche** : Expérience en recherche (0 ou 1).

## La Cible (Target)

- **Variable d'origine** : Chance of Admit (Probabilité continue entre 0 et 1).
- **Transformation** : Conversion en **Classe Binaire** avec un seuil de **0.75**.
  - $\geq 0.75$  : **Admis (1)**
  - $< 0.75$  : **Rejeté (0)**


# Analyse Exploratoire & Nettoyage

## 1. Valeurs Manquantes

- Analyse : Vérification de la complétude du dataset.
- Résultat : Aucune valeur manquante détectée (dataset complet).

## 2. Traitement des Outliers (Valeurs Aberrantes)

- **Méthode** : Utilisation de l'intervalle interquartile (IQR).
- **Pourquoi** ? Les valeurs extrêmes faussent la Régression Logistique.
- **Action** : Suppression automatique des lignes aberrantes pour garantir un modèle robuste.




# Corrélation des Variables

## Analyse de la Heatmap

- Nous avons analysé les liens entre les critères d'admission.

## Observations Clés

- Forte corrélation** : Le **CGPA** (Moyenne générale) et le **GRE Score** sont très fortement liés à l'admission.
- Impact de la Recherche** : Avoir une expérience de recherche augmente significativement les chances.
- Indépendance** : Les lettres de recommandation (LOR) sont moins corrélées aux scores bruts, apportant une information complémentaire.





# Prétraitement Avancé

## 1. Normalisation (StandardScaler)

- **Problème** : Le GRE va jusqu'à 340, le CGPA jusqu'à 10.
- **Solution** : Mise à l'échelle (Moyenne = 0, Écart-type = 1).
- **Nécessité** : Indispensable pour la convergence de la Régression Logistique.

## 2. Gestion du Déséquilibre (Oversampling)

- **Constat** : Il y a naturellement moins d'admis que de rejetés (ou inversement selon le seuil).
- **Technique utilisée** : **Random Oversampling** (Sur-échantillonnage aléatoire).
- **Principe** : Dupliquer aléatoirement des exemples de la classe minoritaire pour que le modèle apprenne équitablement les deux cas.
- **Précaution** : Appliqué uniquement sur le jeu d'entraînement (Train Set) pour éviter toute fuite d'information (Data Leakage).



# Modélisation & Algorithmes

Nous avons entraîné et comparé deux algorithmes majeurs vus en cours :

## Modèle A : Régression Logistique

- **Type** : Modèle Linéaire.
- **Pourquoi ?** Simple, rapide et très efficace quand les relations sont proportionnelles (ex: plus la note monte, plus la chance monte).

## Modèle B : Arbre de Décision

- **Type** : Modèle Non-Linéaire.
- **Paramètres** : Critère **Gini**, Profondeur maximale limitée pour éviter le sur-apprentissage.
- **Pourquoi ?** Capable de capturer des règles de décision complexes ("Si CGPA > 9 et Recherche = 1 Alors...").


# Résultats & Comparaison

Tableau de Performance (sur Test Set)

Modèle	Accuracy (Exactitude)	Précision
Régression Logistique	~93%	Élevée
Arbre de Décision	~85%	Moyenne

## Analyse


- La **Régression Logistique** obtient les meilleurs résultats avec une accuracy de 93%.
- Cela confirme que le processus d'admission suit une logique majoritairement **linéaire** (les notes sont le facteur dominant).



# Analyse de la Matrice de Confusion

Focus sur la performance de notre meilleur modèle (Régression Logistique).

- **Vrais Positifs (TP)** : Candidats admis correctement détectés.
- **Faux Négatifs (FN)** : Candidats admis que le modèle a ratés.
- **Résultat** : Le modèle présente un excellent équilibre, ce qui signifie qu'il est fiable pour les deux classes.





# Conclusion & Perspectives

## Bilan du Projet

- Objectif atteint avec une précision supérieure à **90%** (Régression Logistique).
- **La suppression des outliers et l'oversampling** ont été des étapes décisives pour la performance.
- Le **CGPA** est confirmé comme le critère n°1 pour l'admission.

## Perspectives

- Élargir le dataset (actuellement 500 lignes) pour plus de robustesse.
- Tester des modèles d'ensemble (Random Forest) pour améliorer encore le score de l'Arbre de Décision.
- Explorer des techniques de rééchantillonnage plus avancées (comme SMOTE).